

Análise Técnica de Visão Computacional: Proveedor Virtual FITME

Autor: Manus AI

Data: Maio de 2026

Repositório Analisado: `LiviaMor/fitme`

1. Resumo Executivo

O projeto FITME apresenta uma implementação de proveedor virtual baseada em uma arquitetura de visão computacional clássica (2D), utilizando a biblioteca MediaPipe para extração de pontos-chave corporais (landmarks) e OpenCV para manipulação de imagens. A solução atual foca em viabilizar um Produto Mínimo Viável (MVP) rápido e de baixo custo computacional, operando através da sobreposição bidimensional de peças de roupa (overlay) sobre a silhueta do usuário.

Apesar de ser funcional para demonstrações iniciais e não exigir hardware especializado (GPUs) no backend, a abordagem apresenta limitações intrínsecas significativas em relação ao realismo visual, adaptação tridimensional das peças e preservação de iluminação e texturas. O próprio código-fonte documenta a intenção de evoluir a arquitetura para modelos baseados em difusão (como IDM-VTON ou OOTDiffusion) em fases futuras do produto [1].

2. Arquitetura Atual de Visão Computacional

O pipeline de processamento visual do FITME está concentrado principalmente no serviço `VirtualTryOn` (`fitme-api/app/services/virtual_tryon.py`). O fluxo operacional atual segue uma sequência determinística de etapas clássicas de processamento de imagem.

A primeira etapa consiste na recepção e normalização das imagens. O sistema aceita a foto do cliente e a imagem da roupa (via upload ou URL), aplicando a função utilitária `fix_orientation` para corrigir problemas de rotação introduzidos pelos metadados

EXIF de câmeras de smartphones. Este passo é crucial, pois as redes neurais de detecção de pose são altamente sensíveis à orientação da imagem.

Em seguida, ocorre a extração de características corporais. A imagem do cliente é processada pelo `MediaPipe Pose`, configurado com `model_complexity=2` para priorizar precisão em detrimento da velocidade extrema. O sistema verifica a visibilidade de seis pontos essenciais: ombros esquerdo e direito (landmarks 11 e 12), quadris (23 e 24) e tornozelos (27 e 28). Caso qualquer um destes pontos apresente uma pontuação de confiança inferior a 0.3, o processamento é abortado, garantindo que apenas imagens de corpo inteiro adequadas sejam processadas.

A terceira fase é o isolamento da peça de roupa. O sistema implementa uma técnica de remoção de fundo baseada em limiarização de cores no espaço HSV (Hue, Saturation, Value). Duas máscaras são criadas para detectar fundos brancos e cinza-claros, que são combinadas, dilatadas e invertidas para extrair a peça de roupa e convertê-la para o formato BGRA (com canal de transparência alfa).

A etapa final é o posicionamento e sobreposição. Baseado no tipo de peça selecionado (camiseta, calça, vestido, etc.), o sistema calcula uma região retangular (bounding box) usando as distâncias entre os landmarks corporais. Um aspecto interessante da implementação é o cálculo do ângulo dos ombros utilizando a função arco-tangente, permitindo que a imagem da roupa seja rotacionada via `cv2.warpAffine` para acompanhar a inclinação do corpo do usuário antes de ser sobreposta à imagem original com uma opacidade ajustável.

3. Avaliação Técnica e Limitações

A implementação atual demonstra um bom domínio das ferramentas clássicas de visão computacional, com atenção a detalhes importantes como a rotação adaptativa dos ombros e a correção de orientação EXIF. O uso do MediaPipe garante inferência rápida, permitindo que a API processe requisições em hardware padrão (CPU) com baixa latência.

No entanto, a abordagem de “overlay 2D” possui barreiras arquitetônicas intransponíveis quando o objetivo é alcançar fotorrealismo. O sistema atual não consegue modelar a deformação tridimensional do tecido sobre o volume do corpo, resultando em um aspecto visual de “recorte de papel” (paper doll effect). As dobras naturais da roupa, o caimento (drape), as sombras projetadas pelo corpo e a

iluminação ambiente da foto original do usuário são completamente ignorados durante o processo de sobreposição [2].

Além disso, o método de remoção de fundo por espaço de cor HSV (`cv2.inRange`) é frágil e sujeito a falhas. Se a peça de roupa contiver cores claras semelhantes ao fundo (como uma camiseta branca), partes da própria peça serão erroneamente removidas. Técnicas modernas de segmentação semântica, como o Segment Anything Model (SAM) ou U-Net-based matting, ofereceriam resultados significativamente superiores para esta tarefa específica.

A extração de medidas corporais, implementada no serviço `MultiFrameScanner360`, representa a parte mais sofisticada do repositório em termos algorítmicos. O sistema tenta contornar a limitação de profundidade de câmeras monoculares combinando múltiplos frames capturados em ângulos diferentes (0°, 90°, 180°, 270°) e aplicando a fórmula de aproximação de Ramanujan para elipses na tentativa de calcular circunferências reais. Pesquisas recentes indicam que o MediaPipe, por ter sido treinado focado em cinemática e rastreamento de movimento, tende a subestimar as larguras corporais, especialmente em silhuetas femininas [3]. A abordagem do FITME de usar múltiplas vistas mitiga parcialmente este problema, mas ainda depende de calibração baseada na altura informada pelo usuário.

4. Análise de Alternativas Tecnológicas (Estado da Arte)

O mercado de Virtual Try-On (VTON) evoluiu drasticamente com a introdução de modelos de difusão (Diffusion Models). O código-fonte do FITME menciona explicitamente a intenção de migrar para tecnologias como IDM-VTON ou OOTDiffusion. Abaixo, apresentamos uma comparação das principais alternativas open-source disponíveis atualmente [4].

Modelo / Tecnologia	Arquitetura Base	Vantagens Principais	Limitações e Desafios
Overlay (Atual)	OpenCV + MediaPipe	Custo zero, latência em milissegundos, roda em CPU.	Fotorrealismo nulo, sem caimento 3D, remoção de fundo frágil.
VITON-HD	GANs (Generative Adversarial Networks)	Resolução superior a métodos antigos (1024x768), warping razoável.	Artefatos em áreas desalinhadas, perda de detalhes finos da textura da roupa.
OOTDiffusion	Stable Diffusion 1.5 (Dual UNet)	Boa integração da roupa, suporta prompts de texto auxiliares.	Não suporta peças da parte inferior (calças), código legado apresenta instabilidades.
IDM-VTON	Stable Diffusion XL (SDXL)	Excelente preservação de textura, adaptação realista de luz e sombra.	Requer GPUs potentes (VRAM > 16GB), latência alta (20 a 70 segundos por imagem).
CatVTON	Concatenation-based Diffusion	Mais eficiente computacionalmente que o IDM-VTON, alta qualidade.	Ainda exige infraestrutura de GPU dedicada para produção.

5. Recomendações e Plano de Evolução

Para elevar o provador virtual do FITME a um padrão de mercado comercialmente competitivo, a transição para modelos baseados em difusão é o caminho tecnicamente correto. O IDM-VTON (Improved Diffusion Models for Virtual Try-On) desponta atualmente como a solução open-source mais robusta para preservação de detalhes da roupa (como estampas, botões e texturas complexas) [5].

5.1. Evolução de Curto Prazo (Melhorias no MVP)

Antes de uma migração completa para redes neurais generativas pesadas, o pipeline atual pode ser aprimorado substituindo a remoção de fundo baseada em HSV por um modelo de segmentação semântica leve. A integração da biblioteca `rembg` (baseada na arquitetura U²-Net) melhoraria drasticamente o recorte das peças de roupa sem exigir GPUs dedicadas.

Além disso, a extração de contornos corporais pode ser refinada. Atualmente, o cálculo das “bounding boxes” para posicionamento das roupas é estático e baseado apenas nos extremos dos ombros e quadris. A aplicação de algoritmos de Thin Plate Spline (TPS) warping usando os landmarks do MediaPipe como pontos de controle permitiria uma deformação básica da imagem da roupa, ajustando-a melhor à silhueta do usuário antes do blend final.

5.2. Evolução de Médio/Longo Prazo (Arquitetura Generativa)

A implementação de modelos de difusão como o IDM-VTON ou CatVTON exigirá uma mudança arquitetônica profunda no backend do FITME. O processamento não poderá mais ocorrer de forma síncrona no request HTTP do FastAPI devido à alta latência da geração (frequentemente superior a 20 segundos mesmo em GPUs de última geração).

A nova arquitetura deverá adotar um padrão assíncrono com filas de mensagens (como Celery e Redis ou RabbitMQ). O usuário enviaria as imagens e receberia um `job_id`, fazendo *polling* ou recebendo notificações via WebSockets quando o processamento em GPU fosse concluído.

Considerando os custos de infraestrutura para manter instâncias GPU ativas ²⁴/7 na AWS ou GCP, uma alternativa financeiramente viável para startups é o consumo de APIs comerciais especializadas em Virtual Try-On. Serviços como FASHN.ai oferecem endpoints otimizados para esta finalidade, cobrando frações de centavo de dólar por imagem gerada e abstraindo a complexidade de gerenciar instâncias de inferência pesadas [6].

6. Referências

[1] Código-fonte do repositório `LiviaMor/fitme`, arquivo `fitme-api/app/services/virtual_tryon.py`. [2] Islam, T., et al. “Image-based virtual try-on:

Fidelity and simplification.” ScienceDirect, 2024. [3] Zong, W., Yang, J., Baytar, F. “Predicting Human Body Measurements Using MediaPipe Pose Auto-Capture.” Proceedings of 3DBODY.TECH, 2023. [4] Khazaeepoul, P. “Comparing the Top 4 Open Source Virtual Try On (VITON) Models.” FASHN.ai Blog, 2025. [5] “Improving diffusion models for authentic virtual try-on in the wild.” Springer, 2024. [6] FASHN.ai Virtual Try-On API Documentation. Disponível em: <https://fashn.ai/products/api>